

Proyecto Módulo 4: Análisis de ComercioYA

Clase 1: Análisis Inicial de Datos (IDA)

```
In [ ]: import pandas as pd
import numpy as np

# 1. Creamos los datos para poder analizar.
np.random.seed(42)
n = 500
data = {
    'ID_Cliente': range(1, n + 1),
    'Edad': np.random.randint(18, 80, n),
    'Genero': np.random.choice(['Femenino', 'Masculino', 'Otro'], n),
    'Monto_Total': np.random.uniform(10.5, 500.0, n),
    'Visitas_Web': np.random.randint(1, 100, n),
    'Devoluciones': np.random.choice([0, 1], n, p=[0.8, 0.2])
}

df = pd.DataFrame(data)

# Insertar los errores a propósito para la Clase 1 (IDA)
df.loc[0, 'Edad'] = 150
df.loc[1, 'Monto_Total'] = -50.0

# 2. Distinguir variables cuantitativas y categóricas
print("--- Información del Dataset ---")
df.info()

# Género es categórica y Monto_total es cuantitativa.

# 3. Detectar valores inconsistentes o faltantes (IDA)
print("\n--- Valores Faltantes por Columna ---")
print(df.isnull().sum())
print("\n--- Resumen Estadístico para detectar errores ---")
display(df.describe())

# Buscamos valores fuera de lo común
print("Edad máxima detectada:", df['Edad'].max())
print("Monto mínimo detectado:", df['Monto_Total'].min())

# GUARDAR EL ARCHIVO (Asegurando que no haya errores de formato)
df.to_csv('comercio_ya_datos.csv', index=False)

print("¡Archivo 'comercio_ya_datos.csv' creado correctamente")
```

- Hallazgo clase 1: Se detectó un valor atípico de 150 años en la variable Edad y un monto que es negativo. Procederé a limpiarlos.

```
In [ ]: # 4. Filtramos el dataset para eliminar Los errores que detectamos en el IDA
# Nos quedamos solo con edades menores a 100 y montos mayores a 0
df_limpio = df[(df['Edad'] < 100) & (df['Monto_Total'] > 0)].copy()

print("Tamaño del dataset original:", df.shape)
print("Tamaño del dataset limpio:", df_limpio.shape)
print(f"Registros originales: {len(df)}")
print(f"Registros tras la limpieza: {len(df_limpio)}")
print("\nVariable 'df_limpio' creada y lista para la Clase 2.")
```

Clase 2: Estadística Descriptiva.

```
In [ ]: # 1. Calculamos las medidas para el Monto Total de ventas
media = df_limpio['Monto_Total'].mean()
mediana = df_limpio['Monto_Total'].median()
moda = df_limpio['Monto_Total'].mode()[0]
desviacion = df_limpio['Monto_Total'].std()
varianza = df_limpio['Monto_Total'].var()

print(f"--- Análisis de Monto Total ---")
print(f"Media (Promedio): {media:.2f}")
print(f"Mediana (Punto medio): {mediana:.2f}")
print(f"Moda (Valor más repetido): {moda:.2f}")
print(f"Desviación Estándar (Dispersión): {desviacion:.2f}")
print(f"Varianza (Variabilidad): {varianza:.2f}")

# 2. Cuartiles y percentiles (Medidas de posición)
cuartiles = df_limpio['Monto_Total'].quantile([0.25, 0.5, 0.75])
percentiles = df_limpio['Monto_Total'].quantile([0.10, 0.90])

print(f"\nCuartiles:\n{cuartiles}")
print(f"\nPercentiles:\n{percentiles}")
```

```
In [ ]: import matplotlib.pyplot as plt
import seaborn as sns

# Configuración estética
sns.set_theme(style="whitegrid")

# 3. Generar histograma y boxplot para visualizar la distribución y detectar outliers
plt.figure(figsize=(12, 5))

# Subplot 1: Histograma (distribución)
plt.subplot(1, 2, 1)
sns.histplot(df_limpio['Monto_Total'], kde=True, color="skyblue")
plt.title('Distribución de Montos Totales')
plt.xlabel('Monto ($)')
plt.ylabel('Frecuencia')

# Subplot 2: Boxplot (valores atípicos/Outliers)
plt.subplot(1, 2, 2)
sns.boxplot(x=df_limpio['Monto_Total'], color="lightgreen")
plt.title('Boxplot de Montos Totales')
plt.xlabel('Monto ($)')
```

```
plt.tight_layout()
plt.show()

# 4. Calculamos el Rango Intercuartílico (IQR) para detectar outliers
Q1 = df_limpio['Monto_Total'].quantile(0.25)
Q3 = df_limpio['Monto_Total'].quantile(0.75)
IQR = Q3 - Q1

# Definimos Límites
limite_superior = Q3 + 1.5 * IQR
outliers = df_limpio[df_limpio['Monto_Total'] > limite_superior]

print(f"Límite superior para outliers: {limite_superior:.2f}")
print(f"Cantidad de clientes con compras inusualmente altas: {len(outliers)}")
```

- Hallazgos clase 2:
- **Distribución:** El histograma muestra una distribución bastante uniforme/simétrica de la cual observamos que la mayoría de las compras en ComercioYA se concentran entre los 100y400.
- **Boxplot:** No se observan valores atípicos significativos después de la limpieza inicial, lo que indica una base de clientes con montos de compra consistentes.
- **Impacto:** Aunque estos valores son reales, su presencia eleva la media. Para decisiones de marketing masivo, nos basaremos más en la mediana (\${mediana:.2f}) para no dejarnos engañar por los valores extremos.

Clase 3: Correlación y Relaciones entre Variables

```
In [ ]: # 1. Construir scatterplot para analizar la relación más importante.
plt.figure(figsize=(8, 5))
sns.scatterplot(data=df_limpio, x='Visitas_Web', y='Monto_Total', color='coral', al
plt.title('Relación entre Visitas Web y Monto Total Gastado')
plt.xlabel('Cantidad de Visitas')
plt.ylabel('Monto Total ($)')
plt.show()

# 1. Construir matriz de correlación. Seleccionamos solo las columnas numéricas rel.
# 2. Al usar .corr(), Pandas calcula Pearson por defecto. Los valores están en el H
matriz_corr = df_limpio[['Edad', 'Monto_Total', 'Visitas_Web', 'Devoluciones']].cor

print("Matriz de Correlación (Pearson):")
display(matriz_corr)

# 3. Creamos el Mapa de Calor (Heatmap)
plt.figure(figsize=(10, 6))
sns.heatmap(matriz_corr, annot=True, cmap='coolwarm', fmt=".2f", linewidths=0.5)
plt.title('Mapa de Calor de Correlaciones - ComercioYA')
plt.show()
```

Hallazgos de la Clase 3:

- **Interpretación del Coeficiente (R):** En el Mapa de Calor, buscamos la relación `Visitas_Web` y `Monto_Total`. Eso nos da un valor $\{R\} = 0,01$. Es una correlación nula o extremadamente débil. Un valor tan cercano a 0 indica que no existe una relación lineal entre la cantidad de veces que un cliente visita la web y el dinero que termina gastando. Con esto concluimos que en ComercioYA no siempre el que más visita la web es el que más gasta.
- **Correlación Espuria:** Se decidió no incluir la variable `ID_Cliente` en la matriz, ya que cualquier correlación numérica con un número de identificación sería casual y no lógica (espuria).

Clase 4: Regresiones lineales

¿Podemos predecir cuánto gastará un cliente (`Monto_Total`) sabiendo cuántas veces visitó la web (`Visitas_Web`)?

```
In [ ]: import seaborn as sns
import statsmodels.api as sm
from sklearn.metrics import mean_squared_error, mean_absolute_error

# 1. Aplicar modelos con statsmodels. Definimos nuestras variables
# Y es lo que queremos predecir (Variable Dependiente): Monto_Total
# X es la variable que usamos para predecir (Variable Independiente): Visitas_Web

Y = df_limpio['Monto_Total']
X = df_limpio['Visitas_Web']

# Statsmodels necesita que añadamos una constante (interceptor) manualmente
```

```

X = sm.add_constant(X)

# Ajustamos el modelo (OLS: Mínimos Cuadrados Ordinarios)
X_const = sm.add_constant(X)
modelo = sm.OLS(Y, X_const).fit()

# Obtenemos las predicciones para calcular el error y mostramos el resumen de resul
predicciones = modelo.predict(X_const)
print(modelo.summary())

# 2. Calculamos las métricas del archivo
r2 = modelo.rsquared
mse = mean_squared_error(Y, predicciones)
mae = mean_absolute_error(Y, predicciones)

# Mostramos los resultados
print(f"--- Resultados del Modelo ---")
print(f"R-cuadrado (R2): {r2:.4f}")
print(f"Error Cuadrático Medio (MSE): {mse:.2f}")
print(f"Error Absoluto Medio (MAE): {mae:.2f}")
print("\n--- Resumen detallado del modelo ---")
print(modelo.summary())

# 4. Visualizar la regresión con Seaborn
plt.figure(figsize=(10, 6))
sns.regplot(data=df_limpio, x='Visitas_Web', y='Monto_Total',
            line_kws={"color": "red"}, scatter_kws={'alpha': 0.5})
plt.title('Visualización del Modelo de Regresión: Visitas vs Monto')
plt.show()

```

- Hallazgos de la Clase 4:

Significancia de los Predictores: Al observar el $P > |t|$ en el resumen de statsmodels, si es mayor a 0.05, significa que la variable no es un buen predictor.

Interpretación de R2: El valor de R-cuadrado nos indica qué porcentaje de la variación del gasto se explica por las visitas. En este caso, al ser datos simulados aleatoriamente, el R2 suele ser muy bajo (cercano a 0), lo que indica que para ComercioYA las visitas no son el único factor que determina el gasto.

Métricas de Error: El MAE nos indica que, en promedio, nuestras predicciones se alejan del valor real.

Clase 5: Análisis visual de datos

```

In [ ]: import seaborn as sns
import matplotlib.pyplot as plt

# 1. Crear gráficos según proyecto.
# a. Violinplot: Monto Total segmentado por Género
plt.figure(figsize=(10, 6))

```

```

sns.violinplot(data=df_limpio, x='Genero', y='Monto_Total', palette="muted")
plt.title('Distribución del Monto por Género (Violin Plot)')
plt.show()

# b. Jointplot: Relación entre Visitas y Monto con histogramas en los ejes
sns.jointplot(data=df_limpio, x='Visitas_Web', y='Monto_Total', kind="hex", color="
plt.show()

# c. Pairplot: Todas las relaciones numéricas de un vistazo
# Usamos 'hue' para diferenciar por Género visualmente
sns.pairplot(df_limpio[['Edad', 'Monto_Total', 'Visitas_Web', 'Genero']], hue='Gene
plt.show()

# d. FacetGrid: Comparación de Edad vs Monto según si hubo Devolución o no
g = sns.FacetGrid(df_limpio, col="Devoluciones", height=5)
g.map(sns.scatterplot, "Edad", "Monto_Total", alpha=.7)
g.add_legend()
plt.show()

```

- Hallazgos de Clase 5:

Distribución (Violinplot): El gráfico de violín muestra que el gasto medio es similar entre géneros, pero el género ej: Femenino, presenta una mayor concentración de compras en el rango de los \$300.

Densidad (Jointplot): La visualización hexagonal revela que la mayor densidad de clientes se agrupa en el centro del gráfico, confirmando que no hay una relación lineal fuerte.

Relaciones (Pairplot): Se confirma visualmente que las variables no están fuertemente correlacionadas, ya que no se observan patrones o nubes de puntos con direcciones claras.

Comportamiento (FacetGrid): Al segmentar por devoluciones, se observa que los clientes que devuelven productos no pertenecen a un rango de edad específico, lo que sugiere que el problema no es demográfico.

Clase 6: Personalización y Exportación con matplotlib

In []: `import matplotlib.pyplot as plt`

```

# 1. Creamos una figura con 2 subplots (1 fila, 2 columnas)
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(15, 6))

# --- Gráfico 1: Histograma de Edad (Personalizado) ---
ax1.hist(df_limpio['Edad'], bins=15, color='skyblue', edgecolor='black')
ax1.set_title('Distribución de Edad de Clientes', fontsize=14, fontweight='bold')
ax1.set_xlabel('Edad')
ax1.set_ylabel('Frecuencia')
ax1.grid(axis='y', linestyle='--', alpha=0.7)

```

```
# --- Gráfico 2: Monto Total por Género (Gráfico de Barras) ---
promedio_genero = df_limpio.groupby('Genero')['Monto_Total'].mean()
ax2.bar(promedio_genero.index, promedio_genero.values, color=['pink', 'lightblue'],
ax2.set_title('Promedio de Gasto por Género', fontsize=14, fontweight='bold')
ax2.set_xlabel('Género')
ax2.set_ylabel('Monto Promedio ($)')

# Añadir una anotación
ax2.annotate('Gasto más alto', xy=(0, promedio_genero.max()), xytext=(0.5, promedio
            arrowprops=dict(facecolor='black', shrink=0.05))

plt.tight_layout()
plt.show()
```

```
In [ ]: plt.figure(figsize=(10, 6))

# Graficamos Visitas vs Monto, pero diferenciando por puntos
for genero in df_limpio['Genero'].unique():
    subset = df_limpio[df_limpio['Genero'] == genero]
    plt.scatter(subset['Visitas_Web'], subset['Monto_Total'], label=genero, alpha=0.5)

# Personalización total
plt.title('Análisis Detallado: Visitas vs Gasto por Género', fontsize=16)
plt.xlabel('Visitas a la Plataforma', fontsize=12)
plt.ylabel('Inversión Total del Cliente ($)', fontsize=12)
plt.legend(title='Categoría de Género', loc='upper right')
plt.xlim(0, 100) # Ajuste de Límites (Ticks)
plt.ylim(0, 600)

# Guardar el gráfico para el informe
plt.savefig('grafico_final_comercioya.png', dpi=300, bbox_inches='tight')
plt.show()

print("✅ Gráfico exportado como 'grafico_final_comercioya.png'")
```

Conclusiones del Análisis EDA - ComercioYA

1. **Perfil del Cliente:** La distribución de edad se concentra principalmente en [20 - 70], lo que sugiere un público objetivo joven/adulto.
2. **Calidad de Datos (IDA):** Se identificaron y corrigieron valores atípicos imposibles (Edad 150, Montos negativos), asegurando la integridad del análisis.
3. **Comportamiento del Cliente:** El gasto promedio ronda los \$250, sin diferencias drásticas entre géneros.
4. **Impacto del Género:** No existen diferencias significativas en el gasto promedio entre géneros, por lo que las campañas pueden ser generales.
5. **Eficacia de la Web:** Dado que la correlación entre visitas y monto es baja (visto en Clase 3 y 4), se recomienda optimizar la tasa de conversión en lugar de solo buscar tráfico masivo.
6. **Análisis de Correlación:** No se detectó una relación fuerte entre el número de visitas y

el monto gastado. Esto sugiere que el marketing debe enfocarse en la *calidad* de la visita más que en la *cantidad*.

7. **Resumen Técnico:** El modelo de regresión lineal y las visualizaciones avanzadas confirman que el comportamiento de compra es multivariado y no depende de una sola métrica.