

# Conclusiones del proyecto modulo 6

Tras el desarrollo de las ocho fases del pipeline de Machine Learning, se presentan las siguientes conclusiones finales:

## 1. Desempeño y selección del modelo

Se evaluaron diversos algoritmos (regresión lineal, KNN y gradient boosting). Si bien los modelos lineales y polinomiales superaron el 0.994 de  $R^2$ , el KNN mostró un desempeño ligeramente inferior (0.965). Con esto se ha seleccionado la **regresión lineal** como el modelo de producción final.

- **Justificación:** Ante la paridad de resultados, se priorizó la **interpretabilidad**. La regresión lineal permite al equipo de analítica comprender de forma directa cómo influye cada variable en el gasto sin la complejidad de un modelo de ensamble.

## 2. Hallazgos del negocio

El modelo revela que el gasto anual del cliente es predecible en un **99,4%** basado en las variables analizadas. El **error medio absoluto (MAE)** de **8.0696** para nuestro modelo seleccionado (regresión lineal) indica que nuestras proyecciones financieras tendrán un margen de error promedio de apenas 8 unidades monetarias por cliente. Esta precisión permite una planificación presupuestaria y proyecciones de ventas altamente confiables para el próximo ciclo fiscal.

## 3. Drivers de gasto (importancia de variables)

A través de los coeficientes del modelo, se identificó que:

- Los **años de membresía** y el **tiempo en la app** son los predictores con mayor impacto positivo en el gasto total.
- Esto sugiere que las campañas de fidelización y la mejora de la experiencia en la aplicación móvil son las estrategias con mayor potencial de retorno de inversión.

## Figura 1: Comparativa de Métricas de Desempeño.


En esta tabla se observa que la Regresión Lineal y la Polinomial presentan el  $R^2$  más alto (0.994) y el error (MAE) más bajo (8.06), superando significativamente al algoritmo KNN Regresor en precisión.

...    --- Tabla Comparativa de Desempeño ---

|   | Modelo               | MAE       | MSE        | RMSE      | R2       |
|---|----------------------|-----------|------------|-----------|----------|
| 0 | Regresión Lineal     | 8.069674  | 105.491973 | 10.270929 | 0.994387 |
| 1 | Regresión Polinomial | 8.171419  | 106.748464 | 10.331915 | 0.994320 |
| 2 | KNN Regresor         | 19.766707 | 644.477277 | 25.386557 | 0.965706 |

C:\Users\jceli\AppData\Local\Temp\ipykernel\_16380\3364620017.py:32: FutureWarning:

**Figura 2: Visualización del Error Medio Absoluto (MAE).** El gráfico permite identificar visualmente la superioridad de los modelos de regresión frente a KNN. Se optó por la Regresión Lineal debido a que ofrece el menor error posible con la estructura más simple.



**Figura 3: Validación con Gradient Boosting**

Se realizó una prueba con un modelo avanzado de ensamble (Gradient Boosting), obteniendo un  $R^2$  de 0.99. Al no presentar una mejora significativa respecto a la Regresión Lineal (que ya alcanzaba el 0.994), se confirma la elección del modelo lineal por su facilidad de interpretación

```
--- Desempeño: Gradient Boosting ---  
MAE: 10.94  
R2: 0.99  
  
--- Comparación Final ---  
Modelo Lineal (5 variables) | R2: 0.99  
Gradient Boosting           | R2: 0.99
```